

La descente de gradient.

Comment une IA apprend de ses erreurs, un pas à la fois.

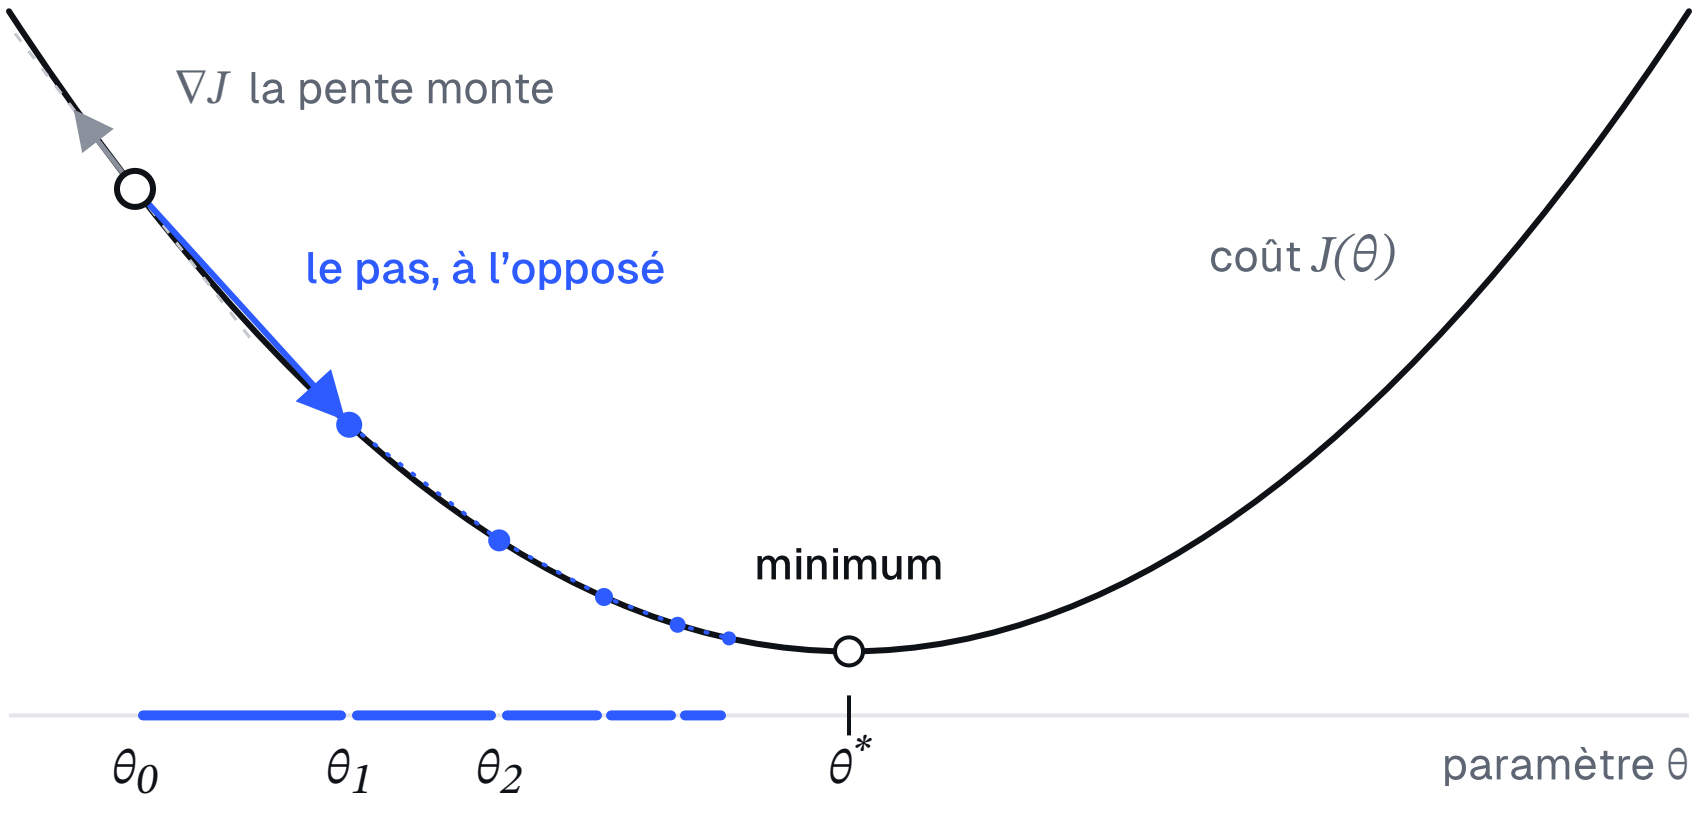
Ladji Lama Kamagate

GLISSEZ →

On sait mesurer l’erreur (N° 05) et lire une pente (N° 06 et 07).

Descendre la pente.

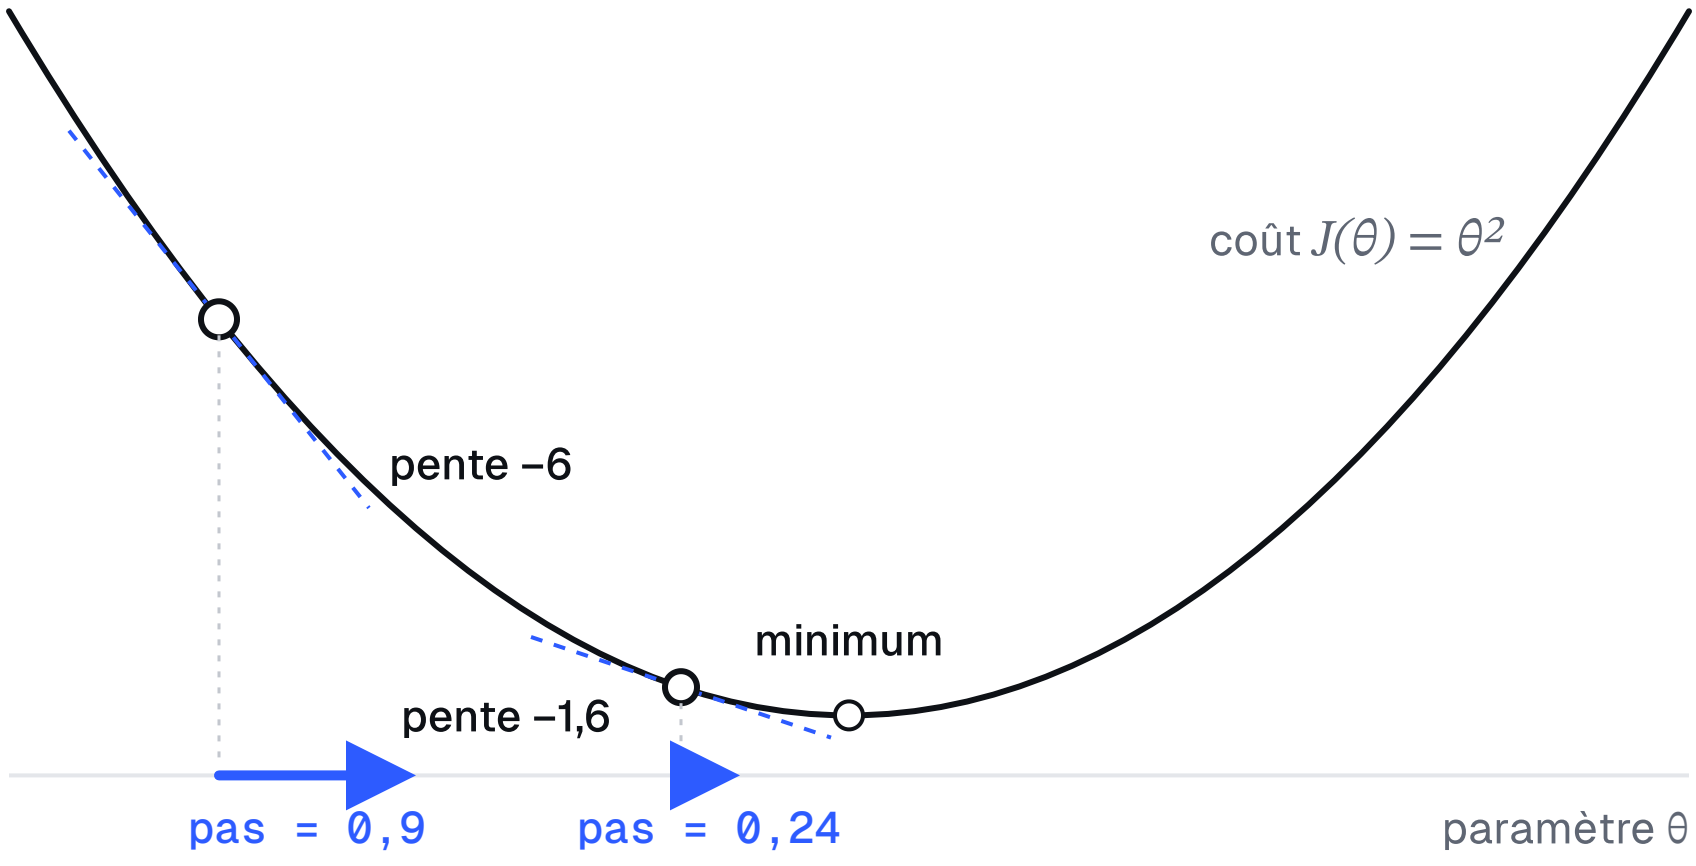
Le modèle ne voit pas toute la courbe du coût J. Il mesure la pente là où il est, fait un pas dans l’autre sens, et recommence.



MÉCANISME

Pente forte, grand pas. Pente faible, petit pas.

Prenons un seul paramètre θ. η, le taux d'apprentissage, est un nombre fixe choisi d'avance, ici 0,15 ; le pas vaut η × la pente. Loin du minimum, la pente est forte : grands pas. Près du minimum, elle s'aplatit : les pas raccourcissent d'eux-mêmes.



LE TAUX RESTE FIXE

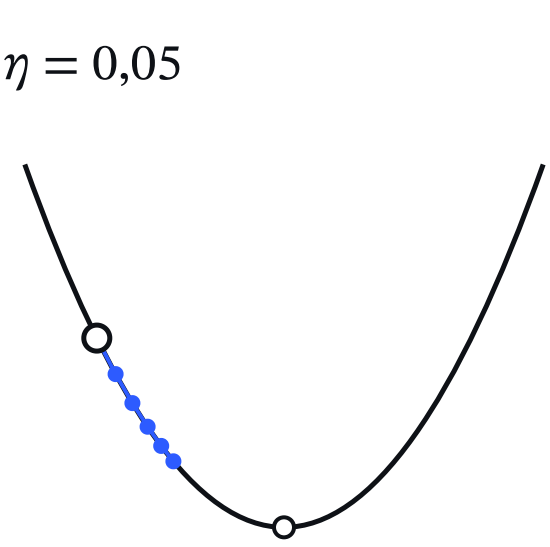
C'est la pente qui diminue : le même η donne **des pas plus courts** quand la courbe s'aplatit.

COMPARAISON

Le bon pas : ni trop petit, ni trop grand.

Même courbe $J(\theta) = \theta^2$, même départ, trois η différents. Seule la taille des pas change, et avec elle tout le comportement de la descente.

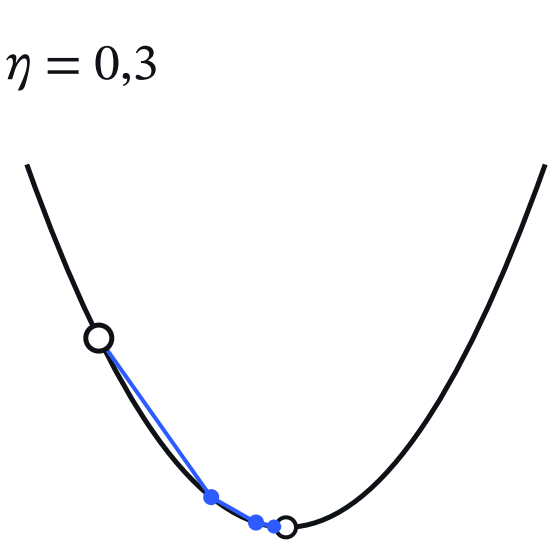
$\eta = 0{,}05$



Trop lent

Après 5 pas, encore loin du minimum.

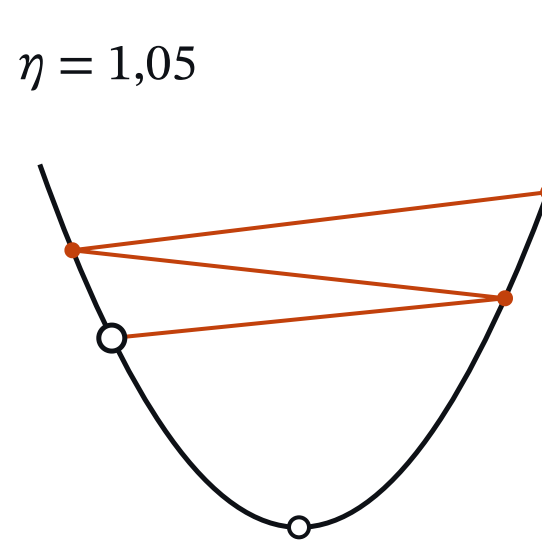
$\eta = 0{,}3$



Convergence

4 pas suffisent pour arriver près du minimum.

$\eta = 1{,}05$



Divergence

Chaque pas saute de l'autre côté, plus haut : le point oscille et diverge.

EN PRATIQUE

Il dépend du problème : chaque modèle et chaque jeu de données a le sien. Un η un peu trop grand fait déjà **osciller** autour du minimum.

FORMULE

Tout tient en une ligne.

Chaque pas suit la même règle. Une itération, c’est un pas : on la répète jusqu’à ce que la pente soit presque nulle, ou pour un nombre d’itérations fixé d’avance.

$$\theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$$

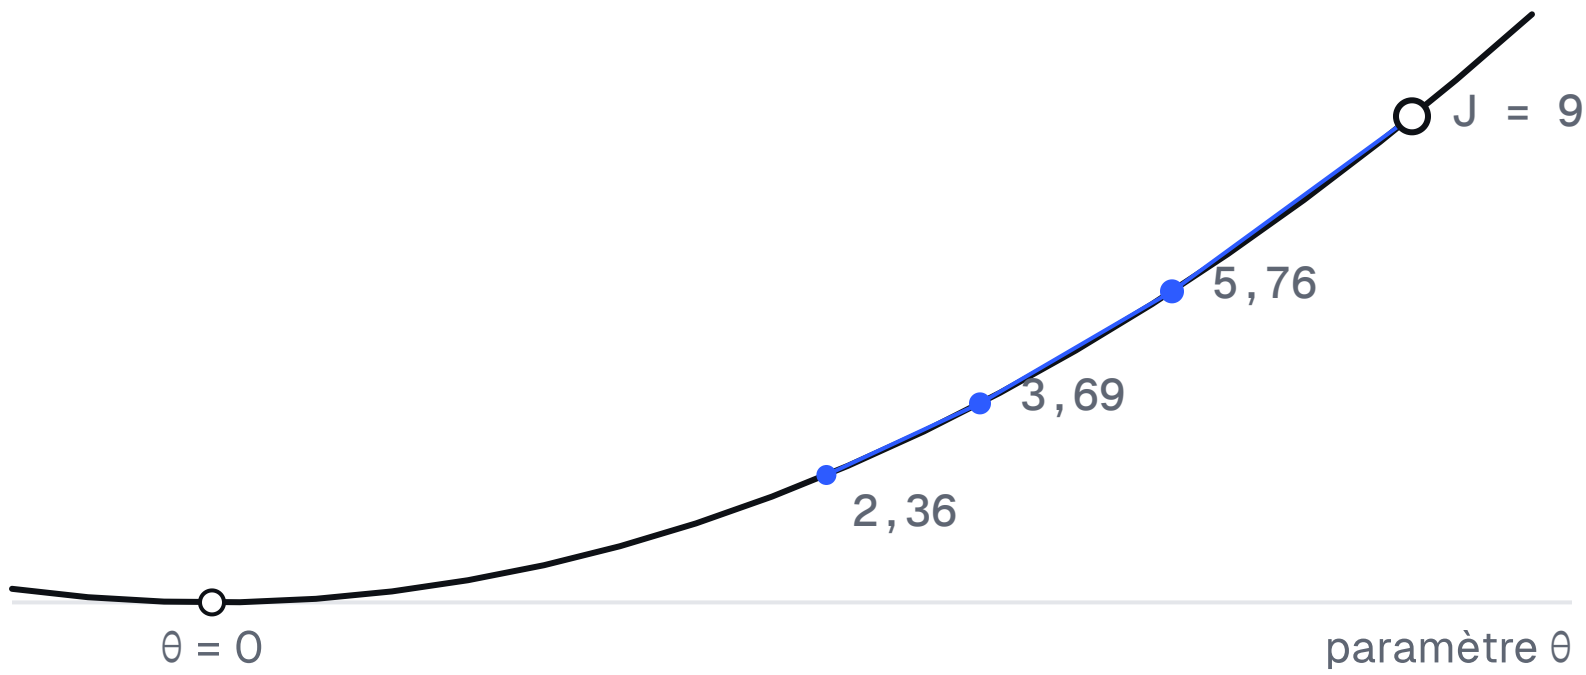
θ_t	les paramètres du modèle à l’itération t ; ici, un seul
$\nabla J(\theta_t)$	le gradient du coût (épisode 07) ; avec un seul paramètre, la pente
η	le taux d’apprentissage : la taille du pas
$-$	on va dans le sens opposé au gradient
θ_{t+1}	les paramètres après ce pas

EXEMPLE CHIFFRÉ

Trois pas, à la main.

Prenons $J(\theta) = \theta^2$, dont la pente vaut 2θ (épisode 06). On part de $\theta = 3$, avec $\eta = 0{,}1$.

Itération	θ	Pente 2θ	Pas η × pente	Nouveau θ
1	3	6	0,6	**2,4**
2	2,4	4,8	0,48	**1,92**
3	1,92	3,84	0,384	**1,536**

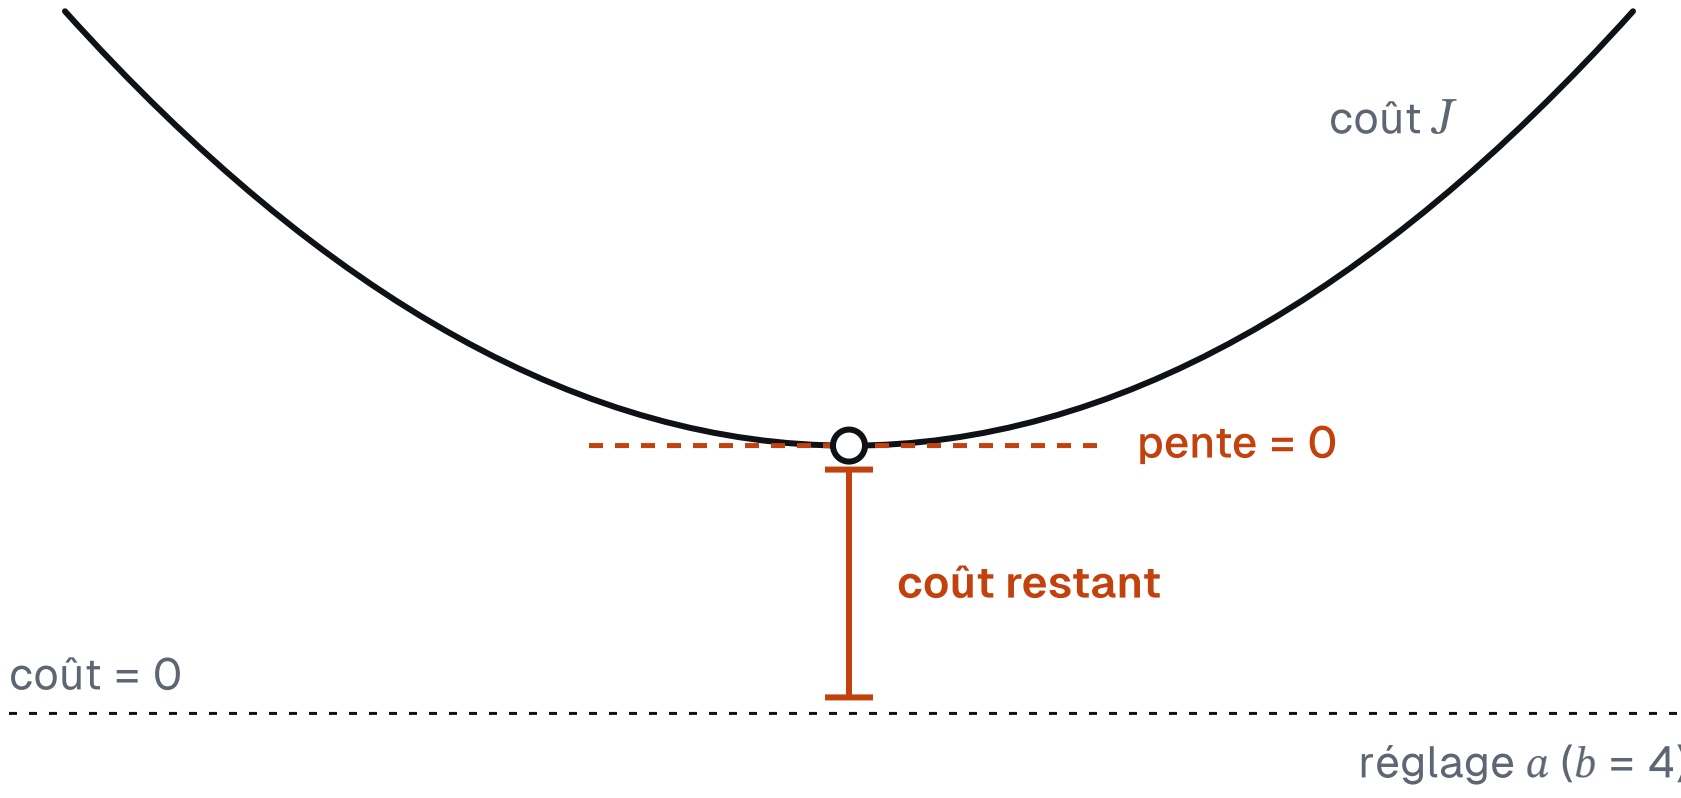


Le coût passe de 9 à 2,36 en trois pas, et chaque pas est plus court que le précédent.

PIÈGE

Pente nulle ne veut pas dire coût nul.

Reprenons le coût des ventes d'Ames selon a, b fixé à 4 (épisode 05). Au creux, la droite de l'épisode 04, la pente est nulle : la descente s'arrête. Pourtant J vaut encore 1030 millions de FCFA au carré : aucune droite ne passe par toutes les ventes.



CE QUE ÇA VEUT DIRE

Plus de pas n'y changent rien : aucun autre réglage de cette droite ne fait mieux. Pour faire baisser J, il faut **changer de modèle**.

À RETENIR

01 Le modèle mesure la pente là où il est, fait un pas dans l'autre sens, et recommence.

02 Le pas vaut η × la pente : près du minimum, les pas raccourcissent d'eux-mêmes.

03 η trop petit : trop lent. Trop grand : le point oscille et diverge.

VÉRIFIEZ-VOUS

Pourquoi les pas raccourcissent-ils près du minimum, alors que η ne change pas ?

RÉPONSE : PAGE 3



ÉPISODE SUIVANT · N° 09

Descente stochastique et mini-lots

Calculer la pente sur toutes les données à chaque pas, ça coûte cher.

Suivez la série et enregistrez ce carrousel pour le relire.

Ladji Lama Kamagate