

Descente stochastique et mini-lots.

Apprendre vite, sans tout relire à chaque pas.

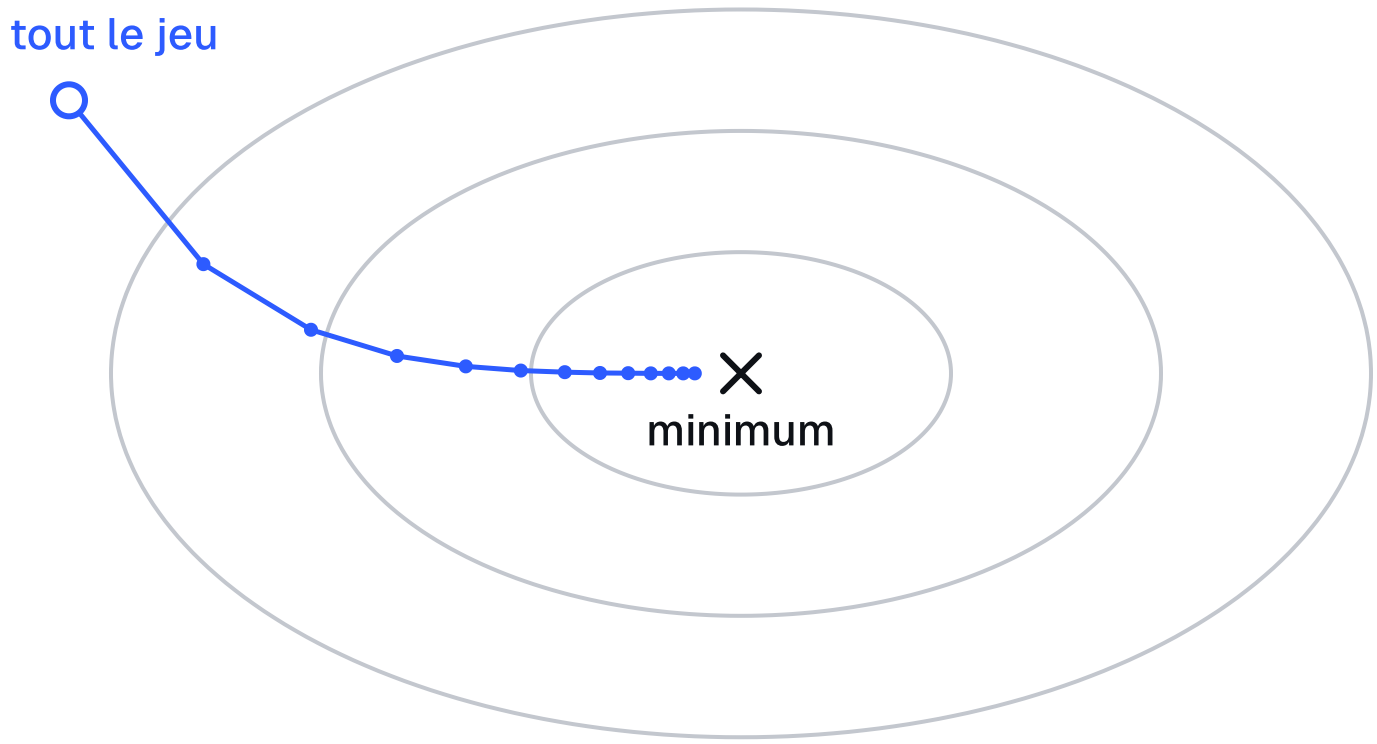
Ladji Lama Kamagate

GLISSEZ →

N° 05 : le coût J ; N° 06 et 07 : sa pente, le gradient ∇J ;
N° 08 : un pas dans l'autre sens.

Tout relire à chaque pas ?

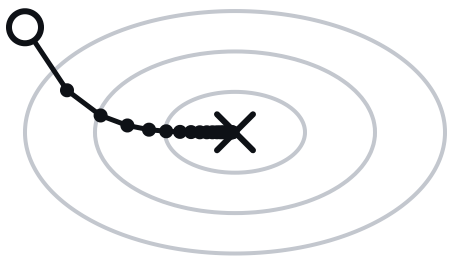
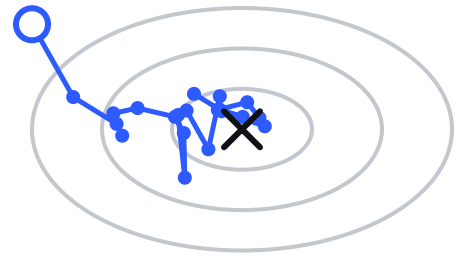
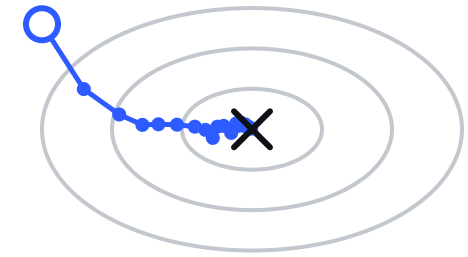
Chaque pas calcule ∇J sur tous les exemples, un calcul par exemple. Imaginons-en un million : un million de calculs pour un seul pas.



COMPARAISON

Combien d’exemples par pas ?

Même carte, même départ. Seul change le nombre d’exemples lus à chaque pas pour calculer ∇J.

Tout le jeu	Un exemple	Un mini-lot
		
Régulier, mais lourd	**Rapide, mais bruité**	**Le compromis**
Chaque pas lit tous les exemples.	Chaque pas lit un exemple tiré au hasard : c’est la descente stochastique (SGD).	Chaque pas lit un mini-lot, souvent de 32 à 256 exemples (usage décrit en 2016).

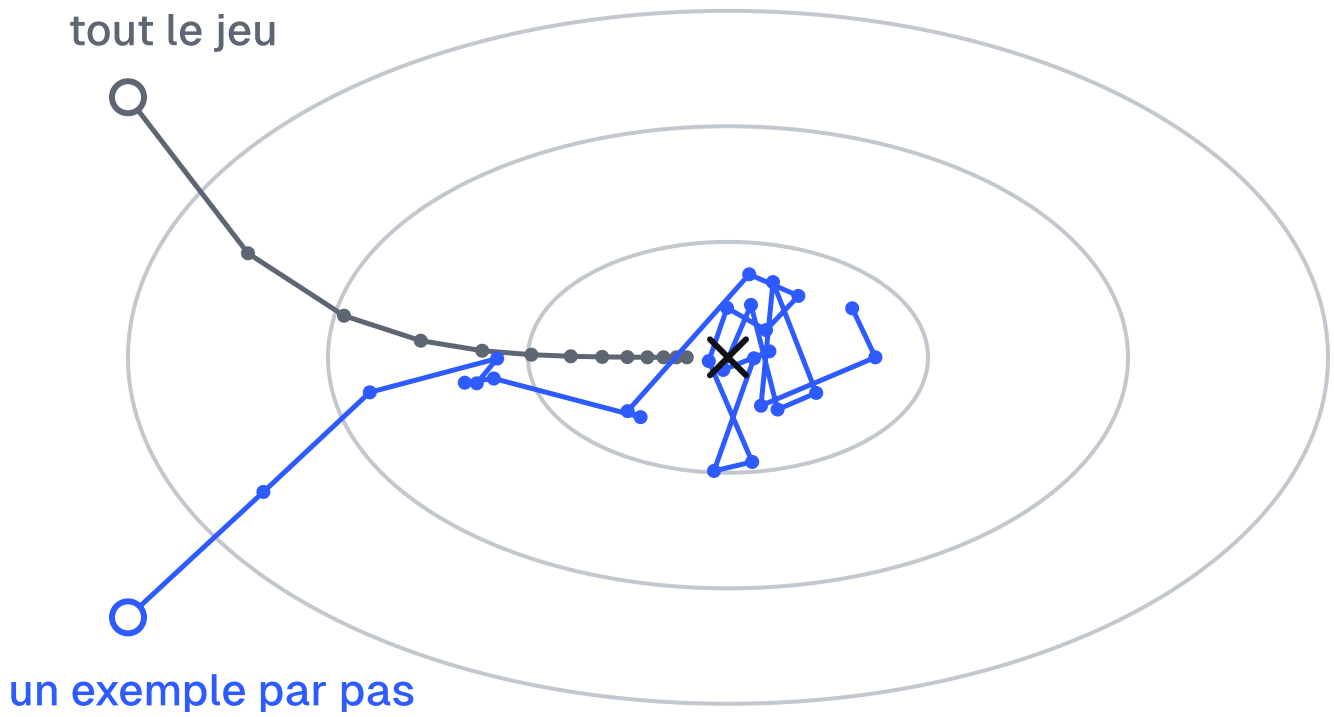
EN PRATIQUE

On dit souvent SGD même avec des mini-lots. Un exemple à la fois fait perdre du temps machine : en temps de calcul, le mini-lot va en général **plus vite** que les deux autres.

MÉCANISME

Faux à chaque pas, juste en moyenne.

Pourquoi la SGD avance-t-elle quand même ? Le ∇J d'un seul exemple dévie, mais en moyenne il indique la même direction que celui de tout le jeu. Les écarts se compensent : le chemin zigzague, puis arrive près du minimum.



UN CAS PARTICULIER

Ici, J n'a qu'**un seul creux**. Avec plusieurs creux, il n'y a en général plus de garantie.

DÉFINITION

Compter en époques.

Si chaque pas ne lit qu’une partie des exemples, combien de pas faut-il pour les voir tous ?

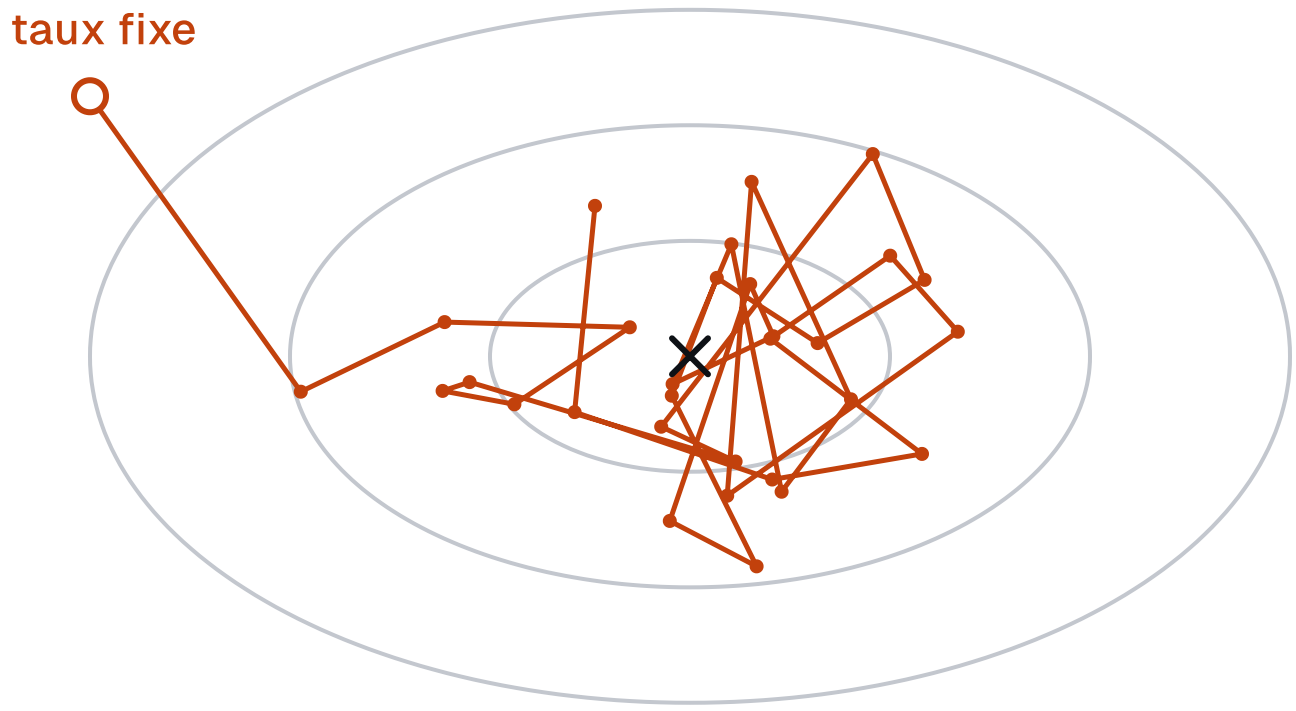
Une époque, c’est un passage complet sur toutes les données.

01	Chaque exemple y est vu une fois, dans un ordre tiré au hasard, qui change d’une époque à l’autre.
02	Tout le jeu à chaque pas : 1 pas par époque.
03	Un exemple à chaque pas : 1500 pas pour 1500 exemples.
04	On fait d’ordinaire plusieurs époques.

PIÈGE

Un taux fixe ne laisse pas le modèle se poser.

Avec un η fixe, les écarts ne disparaissent pas, même au minimum : le modèle rebondit autour sans s'y poser. D'où un η qui décroît au fil des époques, ni trop vite, ni trop lentement.



CE QUE ÇA VEUT DIRE

Un taux qui décroît raccourcit les pas, et les écarts avec eux. En 1951 déjà, Robbins et Monro raccourcissaient les pas d'une suite d'essais bruités pour approcher une solution.

À RETENIR

01 Chaque pas lit un exemple tiré au hasard (SGD) ou un mini-lot, souvent de 32 à 256 en 2016.

02 Faux à chaque pas, juste en moyenne : le chemin zigzague, puis arrive près du minimum.

03 Avec un η fixe, le modèle rebondit autour du minimum : d'où un η qui décroît au fil des époques.

VÉRIFIEZ-VOUS

Pourquoi, avec un η fixe, la SGD ne se pose-t-elle pas au minimum ?

RÉPONSE : PAGE 6



ÉPISODE SUIVANT · N° 10

Minimums locaux et points selle

Et si la courbe avait plusieurs creux ?

Suivez la série et enregistrez ce carrousel pour le relire.

Ladji Lama Kamagate